

Import der Daten in die Business-DB

Datenquelle

Für das Projekt wurden synthetische Testdaten verwendet, die eine Telekommunikationsumgebung simulieren. Die Datensätze wurden teilweise mit Hilfe von KI-generierten Beispielen erstellt und teilweise direkt über SQL-Skripte generiert.

Folgende Datenquellen wurden verwendet:

- Kundendaten (Kunde)
- Tarifdaten (Tarif)
- Vertragsdaten (Vertrag)
- Anruflisten (Anruf)
- SMS-Daten (SMS)
- Marketingaktionen (Marketing_Aktion)

Datenformat

Die Daten wurden zunächst als CSV-Dateien bereitgestellt:

- kunde.csv
- tarif.csv
- vertrag.csv
- anruf.csv
- sms.csv
- marketing_aktion.csv

Die CSV-Dateien enthalten strukturierte Datensätze mit den für die Analyse relevanten Attributen.

Importprozess

Der Import erfolgte durch den **SQL Server Import Flat File Wizard**, mit dem die CSV-Dateien in die Business-Datenbank „**Telekom**“ importiert wurden.

Ablauf:

1. Erstellung der Business-Datenbank „**Telekom**“ mittels SQL-Create-Statements.
2. Bereitstellung der Quelldaten als CSV-Dateien.
3. Import der CSV-Dateien über den **SQL Server Import Flat File Wizard** in die entsprechenden Tabellen der Business-Datenbank.

4. Prüfung der Daten auf Vollständigkeit und Konsistenz.
5. Korrektur und Ergänzung der Daten mithilfe von SQL-Skripten.
6. Nutzung der Business-Datenbank als Datenquelle für den anschließenden ETL-Prozess und die Beladung des Data Warehouse.

Verwendete SQL-Skripte zur Datenvorbereitung

Während der Erstellung der Business-Datenbank wurden verschiedene SQL-Skripte eingesetzt, um Testdaten zu generieren, Beziehungen zwischen den Tabellen herzustellen und die Datenkonsistenz sicherzustellen.

Beispiele:

Zuordnung von Verträgen zu SMS-Datensätzen

USE Telekom

UPDATE dbo.sms

SET vertrag_id = ABS(CHECKSUM(NEWID())) % 1011 + 1;

Verteilung von Marketingkampagnen auf Verträge

USE Telekom

UPDATE [Telekom].[dbo].[vertrag]

SET [kampagne_id] =

CASE

WHEN ABS(CHECKSUM(NEWID())) % 100 < 50 THEN NULL

WHEN ABS(CHECKSUM(NEWID())) % 100 < 65 THEN 1

WHEN ABS(CHECKSUM(NEWID())) % 100 < 75 THEN 2

WHEN ABS(CHECKSUM(NEWID())) % 100 < 85 THEN 3

WHEN ABS(CHECKSUM(NEWID())) % 100 < 90 THEN 4

ELSE 5

END;

Die Skripte dienen der automatisierten Datenverteilung und der Vorbereitung konsistenter Testdaten für den ETL-Prozess.

Datenumfang

Die Business-DB enthält ungefähr:

- 1.000 Kunden
- 1.000 Verträge
- 5.000 Anrufe

- 3.000 SMS
- 5 Tarifmodelle
- 5 Marketingkampagnen

Die Daten wurden so generiert, dass typische Analyseaufgaben eines Telekommunikationsunternehmens durchgeführt werden können. Dazu gehören Marketing-Auswertungen, Churn Analysis, Analysen von SMS- und Anruhfrequenzen, Umsatzanalysen, Tarifanalysen sowie zeitbezogene Auswertungen nach Tageszeit, Wochentag, Monat und Jahr.